

Лабораторная работа №5

Построение типовых моделей АРПСС (ARIMA)

РИ-681223 Черепанов Александр

Вариант №19

```
In [44]: import numpy as np
import numpy.random as rand
import matplotlib.pyplot as plt

import h5py

from statsmodels.tsa import api as tsa
from statsmodels.graphics.tsaplots import plot_acf
from statsmodels.tsa.stattools import acf
from statsmodels.tsa.arima_model import ARIMA

%matplotlib inline

import warnings
warnings.filterwarnings('ignore')
```


Создадим собственные АРПСС ряды первого и второго порядков для изучения их автокорреляционных функций. Создадим два АР(1) процесса первого порядка:

```
In [45]: z1 = np.zeros(100)
z2 = np.zeros(100)

z1[0] = 1
z2[0] = 1

for i in range(1,100):
    z1[i] = 0.8 * z1[i-1] + 0.2 * np.random.randn()
    z2[i] = -0.8 * z2[i-1] + 0.2 * np.random.randn()



plt.figure(figsize = (10, 5))
plt.plot(z1, 'b')
plt.plot(z2, 'r')
plt.show()
```



Теперь построим для этих рядов функции автокорреляции:

```
In [46]: plt.figure(figsize = (10, 5))
plot_acf(z1, lags=50)
plot_acf(z2, lags=50)
plt.show()
```

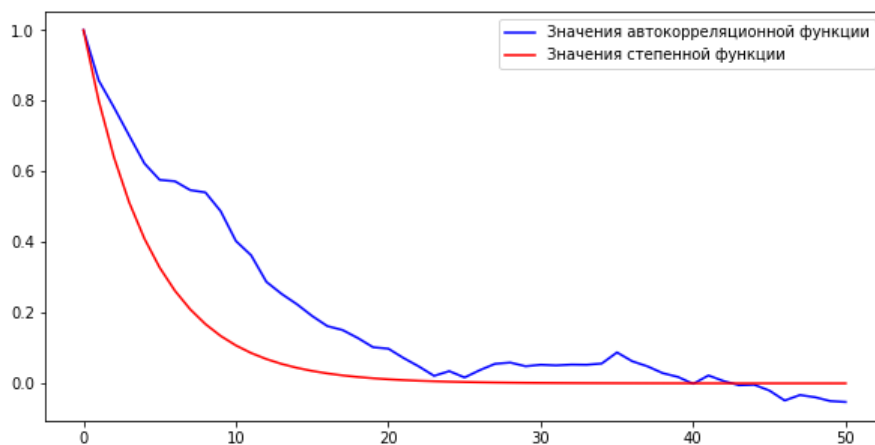
<Figure size 720x360 with 0 Axes>



Для АР с положительным коэффициентом можно заметить, что зависимость с каждым лагом меняется незначительно. Во втором случае, по автокорреляционной функции можно отметить резкие колебания в ВР. Так же можно заметить, что значения автокорреляционных функций при лаге 1 близки к значениям весовых параметров этих процессов.

Удостоверимся, что для модели АР(1) коэффициенты автокорреляции изменяются по степенному закону:

```
In [47]: plt.figure(figsize = (10, 5))
plt.plot(range(51), acf(z1, nlags=50, fft=True), 'b', label='Значения автокорреляционной функции')
plt.plot(range(51), np.array([0.8**l for l in range(51)]), 'r', label='Значения степенной функции')
plt.legend()
plt.show();
```




Аналогичным образом построим два СС(1) процесса среднего-скользящего первого порядка:

```
In [48]: z3 = np.zeros(100)
z4 = np.zeros(100)
ar = 0.2 * np.random.randn(100)

for i in range(1, 100):
    z3[i] = ar[i] - 0.8 * ar[i - 1]
    z4[i] = ar[i] + 0.8 * ar[i - 1]


plt.figure(figsize=(10, 5))
plt.plot(z3, 'b')
plt.plot(z4, 'r')
plt.show()
```



Построим для этих рядов функции автокорреляции:

```
In [49]: plt.figure(figsize = (10, 5))
plot_acf(z3, lags=25)
plot_acf(z4, lags=25)
plt.show()
```


<Figure size 720x360 with 0 Axes>



Убеждаемся, что значение коэффициента автокорреляционной функции при лаге 1 равна следующему выражению:

```
In [50]: def p1(k):
    if k == 0:
        return 1
    if k == 1:
        return (-0.8) / (1 + (-0.8)**2)
    return 0

plt.figure(figsize = (10, 5))
plt.plot(range(26), acf(z3, nlags=25, fft=True), 'b', label='Значения автокорреляционной функции')
plt.plot(range(26), np.array([p1(l) for l in range(26)]), 'r', label='Теоретические значения автокорреляционной функции')
plt.legend()
plt.show();
```



Оценим весовой параметр процесса на основе функции автокорреляции:

```
In [51]: D = (1/acf(z3, nlags=2, fft=True)[1])**2 - 4
theta1 = (-(1/acf(z3, nlags=2, fft=True)[1]) + np.sqrt(D)) / 2
theta2 = (-(1/acf(z3, nlags=2, fft=True)[1]) - np.sqrt(D)) / 2
print(f"theta1 = {theta1}; theta2 = {theta2} => весовой параметр = {theta2}")
```

theta1 = 1.6290729269934823; theta2 = 0.6138460614194473 => весовой параметр = 0.6138460614194473


Создадим временной ряд процесса APCC(1, 1):

```
In [52]: z5 = np.zeros(100)
z6 = np.zeros(100)

z5[0] = 1
z6[0] = 1
ar = 0.2 * np.random.randn(100)

for i in range(1,100):
    z5[i] = 0.8 * z1[i-1] + ar[i] - 0.3 * ar[i-1]
    z6[i] = -0.8 * z2[i-1] + ar[i] - 0.3 * ar[i-1]



plt.figure(figsize= (10, 5))
plt.plot(z5, 'b')
plt.plot(z6, 'r')
plt.show()
```



Построим их автокорреляционные функции:

```
In [53]: plt.figure(figsize = (10, 5))
plot_acf(z5, lags=25)
plot_acf(z6, lags=25)
plt.show()
```

<Figure size 720x360 with 0 Axes>




Используем следующую функцию для создания APCC (2, 2):

```
In [54]: from statsmodels.tsa.arima_process import arma_generate_sample

ar = np.array([0.75, -0.25]) # задаем коэффициенты AP
ma = np.array([0.65, 0.35]) # задаем коэффициенты CC
y = arma_generate_sample(np.r_[1, -ar], np.r_[1, ma], 100) # создаем ВР для APCC (2, 2) = APCC (2, 0, 2) из 100 отсче

plt.figure(figsize=(10, 5))
plt.plot(y)
plt.show()
```



Построим ее автокорреляционную функцию:

```
In [55]: plt.figure(figsize=(10, 5))
plot_acf(y, lags=25)
plt.show()
```

<Figure size 720x360 with 0 Axes>


```

arima3 = ARIMA(TEST, order = (3, 0, 0))
model_fit3 = arima3.fit(dis = False, trend='nc')
print(model_fit3.summary())

```

```

=====
ARMA Model Results
=====
Dep. Variable:          y      No. Observations:      24
Model:                  ARMA(1, 0)  Log Likelihood      -62.425
Method:                 css-mle    S.D. of innovations    3.207
Date:                   Mon, 18 Sep 2023    AIC      128.850
Time:                   10:57:29    BIC      131.206
Sample:                 0      HQIC      129.475
=====

```

```

=====
coef      std err      z      P>|z|      [0.025      0.975]
-----
ar.L1.y    0.7426      0.123      6.053      0.000      0.502      0.983
=====
Roots
=====
Real      Imaginary      Modulus      Frequency
-----
AR.1      1.3465      +0.0000j      1.3465      0.0000
=====

```

```

=====
ARMA Model Results
=====
Dep. Variable:          y      No. Observations:      24
Model:                  ARMA(2, 0)  Log Likelihood      -41.543
Method:                 css-mle    S.D. of innovations    1.201
Date:                   Mon, 18 Sep 2023    AIC      89.086
Time:                   10:57:29    BIC      92.620
Sample:                 0      HQIC      90.024
=====

```

```

=====
coef      std err      z      P>|z|      [0.025      0.975]
-----
ar.L1.y    1.5108      0.056      27.117      0.000      1.402      1.620
ar.L2.y    -0.9641      0.035      -27.509      0.000      -1.033      -0.895
=====
Roots
=====
Real      Imaginary      Modulus      Frequency
-----
AR.1      0.7836      -0.6506j      1.0185      -0.1103
AR.2      0.7836      +0.6506j      1.0185      0.1103
=====

```

```

=====
ARMA Model Results
=====
Dep. Variable:          y      No. Observations:      24
Model:                  ARMA(3, 0)  Log Likelihood      -41.097
Method:                 css-mle    S.D. of innovations    1.172
Date:                   Mon, 18 Sep 2023    AIC      90.193
Time:                   10:57:29    BIC      94.906
Sample:                 0      HQIC      91.443
=====

```

```


=====
coef      std err      z      P>|z|      [0.025      0.975]
-----
ar.L1.y    1.7184      0.222      7.755      0.000      1.284      2.153
ar.L2.y    -1.2995      0.345      -3.770      0.000      -1.975      -0.624
ar.L3.y     0.2216      0.229      0.968      0.333      -0.227      0.670
=====
Roots
=====
Real      Imaginary      Modulus      Frequency
-----
AR.1      0.7786      -0.6645j      1.0236      -0.1124
AR.2      0.7786      +0.6645j      1.0236      0.1124
AR.3      4.3072      -0.0000j      4.3072      -0.0000
=====

```

```

In [60]: plt.figure(figsize= (10, 5))
plt.plot(TEST, label='BP')
plt.plot(model_fit1.fittedvalues, 'r', label='AP(1)')
plt.plot(model_fit2.fittedvalues, 'g', label='AP(2)')
plt.plot(model_fit3.fittedvalues, 'y', label='AP(3)')
plt.legend()
plt.show()

```



Расчитаем весовые коэффициенты для AP моделей только 1 и 2 порядка самостоятельно:

```
In [61]: acf_coefs = acf(TEST, fft=True)
         acf_coefs
```

```
Out[61]: array([ 1.          ,  0.75500976,  0.27235864, -0.2066116 , -0.49581347,
        -0.52955567, -0.35044634, -0.0963739 ,  0.10437004,  0.21646702,
        0.24520358,  0.19968012,  0.11140263,  0.0036976 , -0.10470012,
        -0.16946472, -0.16160427, -0.10778955, -0.07271434, -0.05285789,
        -0.03431416, -0.01650911, -0.01101053,  0.00157628])
```

Весовой коэффициент AP(1)

```
In [62]: theta11 = acf_coefs[1]
         print(theta11)
```

```
0.7550097626743363
```

Весовые коэффициенты AP(2)

```
In [63]: theta21 = (acf_coefs[1]*(1 - acf_coefs[2])) / (1 - acf_coefs[1]**2)
         theta22 = (acf_coefs[2] - acf_coefs[1]**2) / (1 - acf_coefs[1]**2)
         print(theta21, theta22)
```


```
1.2777374692491608 -0.6923456257350362
```

Несмотря на некоторые различия, полученные веса близки к тем, что были получены с помощью функций Python.

Загрузим временной ряд Z из файла. Построим график BP и его автокорреляционную функцию:


```
In [64]: file = h5py.File('19.mat', 'r')
         data = file.get('z19')
         Z = np.array(data)

         plt.figure(figsize = (10, 5))
         plt.plot(Z)
         plt.show()
```



```
In [65]: plt.figure(figsize = (10, 5))
         plot_acf(Z)
         plt.show();
```

```
<Figure size 720x360 with 0 Axes>
```

Оценим порядок АРССмодели с помощью класса ARIMA.

```
In [66]: arimaz = ARIMA(Z, order = (1, 0, 0))
model_fit = arimaz.fit(dis = False) # подгоняем под BP
print(model_fit.summary())

arimaz = ARIMA(Z, order = (2, 0, 0))
model_fit = arimaz.fit(dis = False) # подгоняем под BP
print(model_fit.summary())

arimaz = ARIMA(Z, order = (3, 0, 0))
model_fit = arimaz.fit(dis = False) # подгоняем под BP
print(model_fit.summary())

arimaz = ARIMA(Z, order = (0, 0, 1))
model_fit = arimaz.fit(dis = False) # подгоняем под BP
print(model_fit.summary())

arimaz = ARIMA(Z, order = (0, 0, 2))
model_fit = arimaz.fit(dis = False) # подгоняем под BP
print(model_fit.summary())

arimaz = ARIMA(Z, order = (0, 0, 3))
model_fit = arimaz.fit(dis = False) # подгоняем под BP
print(model_fit.summary())
```

ARMA Model Results

```
=====
Dep. Variable:          y      No. Observations:      128
Model:                ARMA(1, 0)  Log Likelihood      15.832
Method:              css-mle  S.D. of innovations      0.214
Date:                Mon, 18 Sep 2023  AIC      -25.664
Time:                10:57:36  BIC      -17.108
Sample:              0      HQIC      -22.188
=====
```

```
=====
              coef      std err          z      P>|z|      [0.025      0.975]
-----
const          0.0145      0.040      0.366      0.714      -0.063      0.092
ar.L1.y         0.5279      0.075      7.070      0.000      0.382      0.674
=====
```

Roots

```
=====
              Real      Imaginary      Modulus      Frequency
-----
AR.1          1.8943      +0.0000j      1.8943      0.0000
=====
```

ARMA Model Results

```
=====
Dep. Variable:          y      No. Observations:      128
Model:                ARMA(2, 0)  Log Likelihood      15.859
Method:              css-mle  S.D. of innovations      0.214
Date:                Mon, 18 Sep 2023  AIC      -23.717
Time:                10:57:36  BIC      -12.309
Sample:              0      HQIC      -19.082
=====
```

```
=====
              coef      std err          z      P>|z|      [0.025      0.975]
-----
const          0.0144      0.039      0.370      0.712      -0.062      0.091
ar.L1.y         0.5387      0.088      6.109      0.000      0.366      0.711
ar.L2.y        -0.0202      0.088      -0.230      0.818      -0.193      0.152
=====
```

Roots

```
=====
              Real      Imaginary      Modulus      Frequency
-----
AR.1          2.0077      +0.0000j      2.0077      0.0000
AR.2         24.6352      +0.0000j      24.6352      0.0000
=====
```

ARMA Model Results

```
=====
Dep. Variable:          y      No. Observations:      128
Model:                ARMA(3, 0)  Log Likelihood      15.877
=====
```

```

Method:          css-mle  S.D. of innovations      0.213
Date:            Mon, 18 Sep 2023  AIC              -21.755
Time:            10:57:36  BIC                  -7.494
Sample:          0        HQIC                 -15.961

```

```

=====
coef      std err      z      P>|z|      [0.025      0.975]
-----
const      0.0143      0.040      0.362      0.718      -0.063      0.092
ar.L1.y     0.5387      0.088      6.111      0.000      0.366      0.712
ar.L2.y     -0.0296      0.101     -0.295      0.768      -0.227      0.167
ar.L3.y      0.0175      0.090      0.194      0.846      -0.159      0.194

```

Roots

```

=====
Real      Imaginary      Modulus      Frequency
-----
AR.1      1.8400      -0.0000j      1.8400      -0.0000
AR.2      -0.0736      -5.5718j      5.5723      -0.2521
AR.3      -0.0736      +5.5718j      5.5723      0.2521

```

ARMA Model Results

```

=====
Dep. Variable:          y      No. Observations:      128
Model:                  ARMA(0, 1)  Log Likelihood      12.562
Method:                  css-mle  S.D. of innovations      0.219
Date:                    Mon, 18 Sep 2023  AIC              -19.123
Time:                    10:57:36  BIC                  -10.567
Sample:                  0        HQIC                 -15.647

```

```

=====
coef      std err      z      P>|z|      [0.025      0.975]
-----
const      0.0122      0.029      0.424      0.672      -0.044      0.068
ma.L1.y     0.4846      0.070      6.944      0.000      0.348      0.621

```

Roots

```

=====
Real      Imaginary      Modulus      Frequency
-----
MA.1      -2.0637      +0.0000j      2.0637      0.5000

```

ARMA Model Results

```

=====
Dep. Variable:          y      No. Observations:      128
Model:                  ARMA(0, 2)  Log Likelihood      14.366
Method:                  css-mle  S.D. of innovations      0.216
Date:                    Mon, 18 Sep 2023  AIC              -20.732
Time:                    10:57:36  BIC                  -9.324
Sample:                  0        HQIC                 -16.097

```

```

=====
coef      std err      z      P>|z|      [0.025      0.975]
-----
const      0.0133      0.032      0.417      0.677      -0.049      0.076
ma.L1.y     0.5154      0.086      6.011      0.000      0.347      0.684
ma.L2.y     0.1646      0.089      1.846      0.065      -0.010      0.339

```

Roots

```

=====
Real      Imaginary      Modulus      Frequency
-----
MA.1      -1.5661      -1.9037j      2.4651      -0.3596
MA.2      -1.5661      +1.9037j      2.4651      0.3596

```

ARMA Model Results

```

=====
Dep. Variable:          y      No. Observations:      128
Model:                  ARMA(0, 3)  Log Likelihood      16.425
Method:                  css-mle  S.D. of innovations      0.213
Date:                    Mon, 18 Sep 2023  AIC              -22.850
Time:                    10:57:36  BIC                  -8.590
Sample:                  0        HQIC                 -17.056

```

```

=====
coef      std err      z      P>|z|      [0.025      0.975]
-----
const      0.0143      0.037      0.390      0.696      -0.058      0.086
ma.L1.y     0.5418      0.087      6.225      0.000      0.371      0.712
ma.L2.y     0.2576      0.098      2.640      0.008      0.066      0.449
ma.L3.y     0.1659      0.079      2.097      0.036      0.011      0.321

```

Roots

```

=====
Real      Imaginary      Modulus      Frequency
-----
MA.1      -1.7077      -0.0000j      1.7077      -0.5000
MA.2      0.0773      -1.8774j      1.8790      -0.2435
MA.3      0.0773      +1.8774j      1.8790      0.2435

```

Выбираем лучшую модель по параметрам AIC, BIC, HQIC

```

In [67]: arimaz = ARIMA(Z, order = (3, 0, 0))
          model_fit = arimaz.fit(dispatch = False)
          print(model_fit.summary())

```

```

ARMA Model Results
=====
Dep. Variable:          y      No. Observations:      128
Model:                  ARMA(3, 0)      Log Likelihood      15.877
Method:                  css-mle      S.D. of innovations      0.213
Date:                    Mon, 18 Sep 2023      AIC      -21.755
Time:                    10:57:38      BIC      -7.494
Sample:                  0      HQIC      -15.961
=====

```

	coef	std err	z	P> z	[0.025	0.975]
const	0.0143	0.040	0.362	0.718	-0.063	0.092
ar.L1.y	0.5387	0.088	6.111	0.000	0.366	0.712
ar.L2.y	-0.0296	0.101	-0.295	0.768	-0.227	0.167
ar.L3.y	0.0175	0.090	0.194	0.846	-0.159	0.194

```

=====
Roots
=====

```

	Real	Imaginary	Modulus	Frequency
AR.1	1.8400	-0.0000j	1.8400	-0.0000
AR.2	-0.0736	-5.5718j	5.5723	-0.2521
AR.3	-0.0736	+5.5718j	5.5723	0.2521

```

=====

```


Обратимся к прогнозированию на основе АРПСС моделей. Загрузим ВР из файла:

```

In [68]: file = h5py.File('Fort.mat', 'r')
data = file.get('Fort')
Fort = np.array(data)

plt.figure(figsize = (10, 5))
plt.plot(Fort, 'k')
plt.show()

```




Будем производить ретроспективный прогноз. Для этого отрезем от данного ряда последние 24 точки (которые мы и будем прогнозировать):

```

In [69]: Z = Fort[:len(Fort)-24+1] # отрезаем последние 24 точки
t = np.arange(0, len(Z), 1) # временная шкала для регрессии
t = t.reshape(-1,1)

plt.figure(figsize = (10, 5))
plt.plot(Fort, 'k') # исходный ВР
plt.plot(t, Z, 'b') # урезанный ряд
plt.show()

```



```

In [70]: Fort.mean()

```

Out[70]: 3010.183908045977

Модели АРПСС строятся для рядов с около-нулевым средним, что неверно для заданного временного ряда. Построим линейный тренд прогнозируемого ряда, а затем вычтем его из исходного ряда, приведя его к нулевому среднему значению.

```
In [71]: from scipy.optimize import curve_fit

t0 = np.arange(0, len(Fort), 1) # диапазон полного ряда
t0 = t0.reshape(-1,1)


popt, pcov = curve_fit(lambda t, b0, b1: b0 + b1 * t,
                       t.reshape(1,-1)[0], Z.reshape(1,-1)[0])

print(f"b0: {popt[0]}; b1: {popt[1]}")

Zn = Z - (t*popt[1]+popt[0])
Fort24 = Fort[-24:] - (t[-24:]*popt[1]+popt[0])

plt.figure(figsize = (10, 5))
plt.plot(t, (t*popt[1]+popt[0]), 'y')
plt.plot(t, Z, 'k')
plt.plot(t, Zn, 'r')
plt.plot(t0[-24:], Fort24, 'g')
plt.plot(t0[-24:], Fort[-24:], 'b')
plt.show()
```

b0: 3849.2388462962995; b1: -9.589498082978835



Рассматривая различные модели АРПСС порядков от 1 до 3, полагаясь на информационные критерии, можно сделать вывод, что по точности все модели примерно одинаковые. Возьмем модель АРПСС(2, 0, 2) как наилучшую модель по информационным критерием с наименьшим количеством параметров.

```
In [72]: arimaz10 = ARIMA(Zn, order = (1, 0, 0))
model_fit10 = arimaz10.fit(dis = False) # подгоняем под BP
print(model_fit10.summary())

arimaz20 = ARIMA(Zn, order = (2, 0, 0))
model_fit20 = arimaz20.fit(dis = False) # подгоняем под BP
print(model_fit20.summary())

arimaz30 = ARIMA(Zn, order = (3, 0, 0))
model_fit30 = arimaz30.fit(dis = False) # подгоняем под BP
print(model_fit30.summary())

arimaz11 = ARIMA(Zn, order = (1, 0, 1))
model_fit11 = arimaz11.fit(dis = False) # подгоняем под BP
print(model_fit11.summary())

arimaz12 = ARIMA(Zn, order = (1, 0, 2))
model_fit12 = arimaz12.fit(dis = False) # подгоняем под BP
print(model_fit12.summary())

arimaz13 = ARIMA(Zn, order = (1, 0, 3))
model_fit13 = arimaz13.fit(dis = False) # подгоняем под BP
print(model_fit13.summary())

arimaz21 = ARIMA(Zn, order = (2, 0, 1))
model_fit21 = arimaz21.fit(dis = False) # подгоняем под BP
print(model_fit21.summary())

arimaz22 = ARIMA(Zn, order = (2, 0, 2))
model_fit22 = arimaz22.fit(dis = False) # подгоняем под BP
print(model_fit22.summary())
```

```

arimaz23 = ARIMA(Zn, order = (2, 0, 3))
model_fit23 = arimaz23.fit(dispatch = False) # подгоняем под BP
print(model_fit23.summary())

arimaz31 = ARIMA(Zn, order = (3, 0, 1))
model_fit31 = arimaz31.fit(dispatch = False) # подгоняем под BP
print(model_fit31.summary())

arimaz32 = ARIMA(Zn, order = (3, 0, 2))
model_fit32 = arimaz32.fit(dispatch = False) # подгоняем под BP
print(model_fit32.summary())

```

```

=====
ARMA Model Results
=====
Dep. Variable:          y      No. Observations:          151
Model:                ARMA(1, 0)  Log Likelihood          -1193.893
Method:              css-mle    S.D. of innovations          656.374
Date:                Mon, 18 Sep 2023  AIC                2393.787
Time:                10:57:44    BIC                2402.838
Sample:              0      HQIC                2397.464

```

```

=====
coef      std err      z      P>|z|      [0.025      0.975]
-----
const      -2.6755      104.070      -0.026      0.979      -206.648      201.297
ar.L1.y      0.4900      0.072      6.835      0.000      0.349      0.630
=====
Roots
=====
Real      Imaginary      Modulus      Frequency
-----
AR.1      2.0410      +0.0000j      2.0410      0.0000
=====

```

```

=====
ARMA Model Results
=====
Dep. Variable:          y      No. Observations:          151
Model:                ARMA(2, 0)  Log Likelihood          -1191.638
Method:              css-mle    S.D. of innovations          646.513
Date:                Mon, 18 Sep 2023  AIC                2391.275
Time:                10:57:44    BIC                2403.344
Sample:              0      HQIC                2396.178

```

```

=====
coef      std err      z      P>|z|      [0.025      0.975]
-----
const      -1.7869      87.622      -0.020      0.984      -173.523      169.949
ar.L1.y      0.5738      0.081      7.101      0.000      0.415      0.732
ar.L2.y      -0.1728      0.081      -2.141      0.032      -0.331      -0.015
=====
Roots
=====
Real      Imaginary      Modulus      Frequency
-----
AR.1      1.6605      -1.7408j      2.4058      -0.1288
AR.2      1.6605      +1.7408j      2.4058      0.1288
=====

```

```

=====
ARMA Model Results
=====
Dep. Variable:          y      No. Observations:          151
Model:                ARMA(3, 0)  Log Likelihood          -1191.582
Method:              css-mle    S.D. of innovations          646.272
Date:                Mon, 18 Sep 2023  AIC                2393.164
Time:                10:57:44    BIC                2408.251
Sample:              0      HQIC                2399.293

```

```

=====
coef      std err      z      P>|z|      [0.025      0.975]
-----
const      -1.5406      85.263      -0.018      0.986      -168.653      165.571
ar.L1.y      0.5688      0.082      6.920      0.000      0.408      0.730
ar.L2.y      -0.1572      0.093      -1.685      0.092      -0.340      0.026
ar.L3.y      -0.0273      0.082      -0.333      0.739      -0.188      0.133
=====
Roots
=====
Real      Imaginary      Modulus      Frequency
-----
AR.1      1.4483      -1.4613j      2.0574      -0.1257
AR.2      1.4483      +1.4613j      2.0574      0.1257
AR.3      -8.6567      -0.0000j      8.6567      -0.5000
=====

```

```

=====
ARMA Model Results
=====
Dep. Variable:          y      No. Observations:          151
Model:                ARMA(1, 1)  Log Likelihood          -1191.710
Method:              css-mle    S.D. of innovations          646.819
Date:                Mon, 18 Sep 2023  AIC                2391.421
Time:                10:57:44    BIC                2403.490
Sample:              0      HQIC                2396.324

```

```

=====
coef      std err      z      P>|z|      [0.025      0.975]
-----
const      -2.0308      92.282      -0.022      0.982      -182.901      178.840
ar.L1.y      0.2386      0.162      1.471      0.141      -0.079      0.557
=====

```

ma.L1.y 0.3399 0.162 2.101 0.036 0.023 0.657

Roots

	Real	Imaginary	Modulus	Frequency
AR.1	4.1915	+0.0000j	4.1915	0.0000
MA.1	-2.9422	+0.0000j	2.9422	0.5000

ARMA Model Results

```
=====
Dep. Variable:          y      No. Observations:          151
Model:                 ARMA(1, 2)  Log Likelihood          -1186.096
Method:                css-mle   S.D. of innovations        617.448
Date:                  Mon, 18 Sep 2023  AIC                2382.191
Time:                  10:57:45    BIC                 2397.278
Sample:                0          HQIC                 2388.320
=====
```

	coef	std err	z	P> z	[0.025	0.975]
const	-0.5526	8.468	-0.065	0.948	-17.150	16.045
ar.L1.y	0.8027	0.053	15.107	0.000	0.699	0.907
ma.L1.y	-0.4065	0.079	-5.123	0.000	-0.562	-0.251
ma.L2.y	-0.5934	0.076	-7.782	0.000	-0.743	-0.444

Roots

	Real	Imaginary	Modulus	Frequency
AR.1	1.2457	+0.0000j	1.2457	0.0000
MA.1	1.0001	+0.0000j	1.0001	0.0000
MA.2	-1.6850	+0.0000j	1.6850	0.5000

ARMA Model Results

```
=====
Dep. Variable:          y      No. Observations:          151
Model:                 ARMA(1, 3)  Log Likelihood          -1183.892
Method:                css-mle   S.D. of innovations        612.344
Date:                  Mon, 18 Sep 2023  AIC                2379.784
Time:                  10:57:45    BIC                 2397.888
Sample:                0          HQIC                 2387.139
=====
```

	coef	std err	z	P> z	[0.025	0.975]
const	1.3470	14.395	0.094	0.925	-26.867	29.561
ar.L1.y	0.6971	0.129	5.383	0.000	0.443	0.951
ma.L1.y	-0.2834	0.130	-2.172	0.030	-0.539	-0.028
ma.L2.y	-0.3994	0.102	-3.928	0.000	-0.599	-0.200
ma.L3.y	-0.2484	0.106	-2.348	0.019	-0.456	-0.041

Roots

	Real	Imaginary	Modulus	Frequency
AR.1	1.4346	+0.0000j	1.4346	0.0000
MA.1	1.0368	-0.0000j	1.0368	-0.0000
MA.2	-1.3222	-1.4610j	1.9705	-0.3671
MA.3	-1.3222	+1.4610j	1.9705	0.3671

ARMA Model Results

```
=====
Dep. Variable:          y      No. Observations:          151
Model:                 ARMA(2, 1)  Log Likelihood          -1177.439
Method:                css-mle   S.D. of innovations        586.452
Date:                  Mon, 18 Sep 2023  AIC                2364.878
Time:                  10:57:45    BIC                 2379.964
Sample:                0          HQIC                 2371.007
=====
```

	coef	std err	z	P> z	[0.025	0.975]
const	4.4824	17.079	0.262	0.793	-28.992	37.957
ar.L1.y	1.3378	0.067	20.009	0.000	1.207	1.469
ar.L2.y	-0.6152	0.064	-9.554	0.000	-0.741	-0.489
ma.L1.y	-0.9072	0.034	-27.070	0.000	-0.973	-0.841

Roots

	Real	Imaginary	Modulus	Frequency
AR.1	1.0873	-0.6658j	1.2750	-0.0874
AR.2	1.0873	+0.6658j	1.2750	0.0874
MA.1	1.1023	+0.0000j	1.1023	0.0000

ARMA Model Results

```
=====
Dep. Variable:          y      No. Observations:          151
Model:                 ARMA(2, 2)  Log Likelihood          -1156.842
Method:                css-mle   S.D. of innovations        505.551
Date:                  Mon, 18 Sep 2023  AIC                2325.684
Time:                  10:57:45    BIC                 2343.788
Sample:                0          HQIC                 2333.039
=====
```

	coef	std err	z	P> z	[0.025	0.975]
--	------	---------	---	------	--------	--------

```

-----
const      3.8869    34.248     0.113     0.910    -63.239    71.013
ar.L1.y    1.7305     0.005     337.486    0.000     1.720     1.741
ar.L2.y    -0.9964     0.004    -226.644    0.000    -1.005    -0.988
ma.L1.y    -1.7183     0.034    -50.006     0.000    -1.786    -1.651
ma.L2.y     0.9388     0.030     31.306     0.000     0.880     0.998
-----
Roots
=====
Real      Imaginary      Modulus      Frequency
-----
AR.1      0.8684      -0.4995j      1.0018      -0.0831
AR.2      0.8684      +0.4995j      1.0018      0.0831
MA.1      0.9151      -0.4772j      1.0321      -0.0765
MA.2      0.9151      +0.4772j      1.0321      0.0765
-----

ARMA Model Results
=====
Dep. Variable:      y      No. Observations:      151
Model:              ARMA(2, 3)      Log Likelihood      -1158.225
Method:              css-mle      S.D. of innovations      512.912
Date:                Mon, 18 Sep 2023      AIC      2330.450
Time:                10:57:46      BIC      2351.571
Sample:              0      HQIC      2339.031
-----

coef      std err      z      P>|z|      [0.025      0.975]
-----
const      3.9227      21.506     0.182     0.855    -38.229    46.074
ar.L1.y     1.6908      0.028     60.292    0.000     1.636     1.746
ar.L2.y    -0.9394      0.031    -30.422    0.000    -1.000    -0.879
ma.L1.y    -1.5360      0.104    -14.755    0.000    -1.740    -1.332
ma.L2.y     0.4576      0.224     2.046     0.041     0.019     0.896
ma.L3.y     0.2056      0.143     1.439     0.150    -0.074     0.486
-----
Roots
=====
Real      Imaginary      Modulus      Frequency
-----
AR.1      0.8999      -0.5046j      1.0317      -0.0813
AR.2      0.8999      +0.5046j      1.0317      0.0813
MA.1      1.0131      -0.3430j      1.0696      -0.0520
MA.2      1.0131      +0.3430j      1.0696      0.0520
MA.3      -4.2518      -0.0000j      4.2518      -0.5000
-----

ARMA Model Results
=====
Dep. Variable:      y      No. Observations:      151
Model:              ARMA(3, 1)      Log Likelihood      -1176.190
Method:              css-mle      S.D. of innovations      581.382
Date:                Mon, 18 Sep 2023      AIC      2364.381
Time:                10:57:46      BIC      2382.484
Sample:              0      HQIC      2371.735
-----

coef      std err      z      P>|z|      [0.025      0.975]
-----
const      4.9579      16.909     0.293     0.769    -28.184    38.099
ar.L1.y     1.2441      0.087     14.227    0.000     1.073     1.416
ar.L2.y    -0.4369      0.128     -3.409    0.001    -0.688    -0.186
ar.L3.y    -0.1354      0.084     -1.603    0.109    -0.301     0.030
ma.L1.y    -0.8892      0.035    -25.087    0.000    -0.959    -0.820
-----
Roots
=====
Real      Imaginary      Modulus      Frequency
-----
AR.1      1.0098      -0.6228j      1.1864      -0.0880
AR.2      1.0098      +0.6228j      1.1864      0.0880
AR.3      -5.2451      -0.0000j      5.2451      -0.5000
MA.1      1.1246      +0.0000j      1.1246      0.0000
-----

ARMA Model Results
=====
Dep. Variable:      y      No. Observations:      151
Model:              ARMA(3, 2)      Log Likelihood      -1158.884
Method:              css-mle      S.D. of innovations      515.657
Date:                Mon, 18 Sep 2023      AIC      2331.768
Time:                10:57:46      BIC      2352.889
Sample:              0      HQIC      2340.349
-----

coef      std err      z      P>|z|      [0.025      0.975]
-----
const      3.4911      22.289     0.157     0.876    -40.195    47.178
ar.L1.y     1.7665      0.122     14.451    0.000     1.527     2.006
ar.L2.y    -1.0699      0.207     -5.158    0.000    -1.476    -0.663
ar.L3.y     0.0627      0.129     0.486     0.627    -0.190     0.315
ma.L1.y    -1.6988      0.094    -17.982    0.000    -1.884    -1.514
ma.L2.y     0.8251      0.049     16.766    0.000     0.729     0.922
-----
Roots
=====
Real      Imaginary      Modulus      Frequency
-----
AR.1      0.8872      -0.5059j      1.0213      -0.0825
AR.2      0.8872      +0.5059j      1.0213      0.0825

```

AR.3	15.2995	-0.0000j	15.2995	-0.0000
MA.1	1.0295	-0.3901j	1.1009	-0.0577
MA.2	1.0295	+0.3901j	1.1009	0.0577

```
In [73]: arimaz22 = ARIMA(Zn, order = (2, 0, 2))
model_fit22 = arimaz22.fit(dis = False) # подгоняем под ВР
print(model_fit22.summary())
```

```
=====
                    ARMA Model Results
=====
Dep. Variable:          y      No. Observations:      151
Model:                  ARMA(2, 2)  Log Likelihood    -1156.842
Method:                  css-mle    S.D. of innovations  505.551
Date:                   Mon, 18 Sep 2023  AIC            2325.684
Time:                   10:57:49    BIC              2343.788
Sample:                 0          HQIC             2333.039
=====
```

	coef	std err	z	P> z	[0.025	0.975]
const	3.8869	34.248	0.113	0.910	-63.239	71.013
ar.L1.y	1.7305	0.005	337.486	0.000	1.720	1.741
ar.L2.y	-0.9964	0.004	-226.644	0.000	-1.005	-0.988
ma.L1.y	-1.7183	0.034	-50.006	0.000	-1.786	-1.651
ma.L2.y	0.9388	0.030	31.306	0.000	0.880	0.998

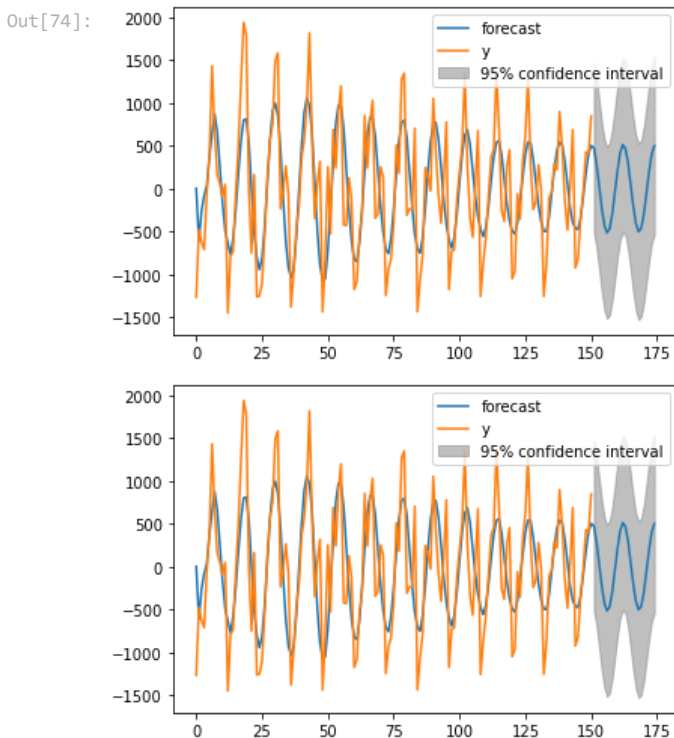
```
=====
                        Roots
=====
```

	Real	Imaginary	Modulus	Frequency
AR.1	0.8684	-0.4995j	1.0018	-0.0831
AR.2	0.8684	+0.4995j	1.0018	0.0831
MA.1	0.9151	-0.4772j	1.0321	-0.0765
MA.2	0.9151	+0.4772j	1.0321	0.0765

```
=====
```

Построим график прогноза по данной модели вместе с доверительными интервалами:

```
In [74]: model_fit22.plot_predict(0, len(Fort))
```




Рассмотрим как этот прогноз по АРПСС модели соотносится с исходными известными 24 прогнозными точками. Вычтем из исходного ряда Fort линейный тренд и соотнесем их на одном изображении:

```
In [75]: popt, pcov = curve_fit(lambda t, b0, b1: b0 + b1 * t,
                               t.reshape(1,-1)[0], Z.reshape(1,-1)[0])

trend_as_func_of_t0 = t0*popt[1]+popt[0]

plt.figure(figsize = (10, 5))
model_fit22.plot_predict(0, len(Fort)) # прогноз по АРПСС
plt.plot(t0, Fort-(trend_as_func_of_t0), 'r') # исходный ВР минус тренд
plt.show();
```

<Figure size 720x360 with 0 Axes>



Получим прогнозные значения по модели АРПСС и используем эти значения для оценки точности прогноза:

```
In [76]: # Средняя ошибка прогноза
def MAE(pred, real):
    return np.mean(np.abs(pred - real))

# СКВО прогноза
def MSD(pred, real):
    return np.sqrt(np.mean((pred - real)**2))

# Средняя ошибка аппроксимации
def MAPE(pred, real):
    return np.mean(np.abs((real - pred) / real))


def res_evaluation(pred, real, title=""):
    print(
        f"Оценка точности прогноза {title}\n"
        f"Средняя ошибка прогноза: {np.round(MAE(pred, real),2)}\n",
        f"СКВО прогноза: {np.round(MSD(pred, real),2)}\n",
        f"Средняя ошибка аппроксимации: {np.round(MAPE(pred, real),2) * 100}%\n"
    )
```

```
In [77]: res_evaluation(model_fit22.predict(len(Z), len(Fort)), (Fort-(trend_as_func_of_t0))[-24:])
```

```
Оценка точности прогноза
Средняя ошибка прогноза: 517.42
СКВО прогноза: 642.58
Средняя ошибка аппроксимации: 229.99999999999997%
```

Можно заметить, что средняя ошибка аппроксимации для данной модели больше 100 процентов. Это означает, что ошибки намного больше, чем фактические значения. Тем не менее, метрики MAE и MSD все еще достаточно информативны.

```
In [78]: plt.plot(model_fit.predict(len(Z), len(Fort)), label='predicted')
plt.plot((Fort-(trend_as_func_of_t0))[-24:], label='real')
plt.legend()
plt.show()
```



Также попробуем построить АРПСС модель для прогнозирования данного ряда, но без исходного вычитания из него линейного тренда:

```
In [79]: arimaz22r = ARIMA(Z, order = (2, 0, 2))
model_fit22r = arimaz22r.fit(dispatch = False) # подгоняем под BP
print(model_fit22r.summary())
```

```
=====
                    ARMA Model Results
=====
Dep. Variable:          y      No. Observations:          151
Model:                ARMA(2, 2)  Log Likelihood          -1215.319
Method:                css-mle    S.D. of innovations          744.434
Date:                  Mon, 18 Sep 2023    AIC              2442.639
Time:                  10:58:30            BIC              2460.742
Sample:                0                HQIC             2449.993
```


	coef	std err	z	P> z	[0.025	0.975]
const	-70.7118	2143.390	-0.033	0.974	-4271.678	4130.255
ar.L1.y	1.9950	nan	nan	nan	nan	nan
ar.L2.y	-0.9951	nan	nan	nan	nan	nan
ma.L1.y	-1.2469	0.107	-11.693	0.000	-1.456	-1.038
ma.L2.y	0.2469	0.106	2.322	0.020	0.039	0.455

Roots

	Real	Imaginary	Modulus	Frequency
AR.1	1.0024	-0.0101j	1.0024	-0.0016
AR.2	1.0024	+0.0101j	1.0024	0.0016
MA.1	1.0000	+0.0000j	1.0000	0.0000
MA.2	4.0498	+0.0000j	4.0498	0.0000


```
In [80]: model_fit22r.plot_predict(0, len(Fort))
```

Out[80]:



```
In [81]: plt.figure(figsize = (10, 5))
model_fit22r.plot_predict(0, len(Fort)) # прогноз по АРСС
plt.plot(t0, Fort, 'r')
plt.show()
```

<Figure size 720x360 with 0 Axes>



В данном случае значение метрик MAE и MSD немного хуже, чем для рядов с около-нулевым средним. При этом теперь значение метрики MAPE имеет смысл.

```
In [82]: res_evaluation(model_fit22r.predict(len(Z), len(Fort)), Fort[-24:])
```

Оценка точности прогноза
Средняя ошибка прогноза: 546.65
СКВО прогноза: 703.72
Средняя ошибка аппроксимации: 31.0%